

RÔ AI RAG ASSISTANT

Kiến trúc hệ thống, bộ công nghệ và kịch bản trình bày

Mục tiêu của đồ án

Hệ thống trả lời câu hỏi từ tài liệu do Admin quản lý. Rô chỉ dùng evidence tìm được trong Knowledge Base, sau đó mới gọi Gemini để sinh câu trả lời và hiển thị nguồn tham khảo.

Bản đồ kiến trúc

1. Người dùng Streamlit	2. FastAPI API layer	3. RAG service Điều phối
Chọn tài liệu Đặt câu hỏi	Validate request Route đúng service	Evidence gate Citation
4. E5 local Embedding vector	5. Qdrant Local Top-K semantic search	6. Gemini 3.5 Flash Generation cloud
Tài liệu: passage: Câu hỏi: query:	Filter document ID Payload metadata	Chỉ nhận Top-K evidence Sinh text answer

Dữ liệu lưu ở đâu?

E5 model chạy local trên máy backend. Qdrant Local lưu vector/chunk tại data/qdrant. SQLite lưu documents, conversations và messages tại data/database. Gemini chạy generation inference trên hạ tầng Google qua API. File gốc upload nằm tại data/uploads.

Bộ công nghệ đã chốt

Thành phần	Công nghệ	Vai trò và lý do chọn
Ngôn ngữ	Python	Một ngôn ngữ cho UI, API, xử lý tài liệu và AI pipeline.
Frontend	Streamlit	Tạo UI chat/upload nhanh, trực quan, phù hợp lab và demo.
Backend	FastAPI	Route rõ ràng, validate schema, tách UI khỏi business logic.
PDF / DOCX / PPTX	PyMuPDF / python-docx / python-pptx	Trích text, giữ trang PDF và slide PPTX làm citation.
Chunking	LangChain Text Splitters	Cắt theo đoạn/câu trước khi cắt cứng, có overlap giữ ngữ cảnh.
Embedding	intfloat/multilingual-e5-small	Đa ngôn ngữ, nhẹ, chạy local; phù hợp tài liệu tiếng Việt.
Vector DB	Qdrant Local	Semantic search Top-K, filter theo document ID, không cần cloud/Docker.
LLM	Gemini 3.5 Flash API	Sinh câu trả lời từ evidence; inference cloud qua Google API.
History	SQLite	Local, không cần server riêng, giữ chat qua restart.
Testing	pytest	Kiểm tra chunk metadata và các chức năng cốt lõi nhanh.

Lý do không làm kiến trúc phình to

Đây là baseline RAG local có một provider LLM. Không dùng multi-provider router như OmniRoute vì tăng cấu hình, chi phí test và điểm lỗi nhưng không cần thiết cho yêu cầu demo. Khi mở rộng thật, có thể thêm authentication/RBAC, OCR, reranker, monitoring và multi-provider.

Hai luồng hoạt động cần trình bày

A. Luồng Admin: index tài liệu

1. Admin upload PDF/DOCX/PPTX/TXT trên Streamlit.
2. documents.py nhận UploadFile, tạo temp file rồi gọi chung ingestion_service.index_file().
3. Loader trích text và metadata vị trí: trang PDF, slide PPTX hoặc nội dung DOCX/TXT.
4. Chunking làm sạch, chia đoạn 900 ký tự, overlap 150 ký tự, giữ document_id/filename/location.
5. E5 local encode passage: + chunk thành vector normalized.
6. Qdrant upsert vector + payload. Chỉ sau thành công SQLite mới đổi trạng thái thành READY.

B. Luồng User: hỏi đáp RAG

1. User chọn tài liệu READY và gửi câu hỏi từ Streamlit.
2. chat.py validate ChatRequest, lấy history gần trong SQLite và gọi rag_service.answer_question().
3. E5 local encode query: + câu hỏi. Với follow-up ngắn, thêm câu user gần để retrieval hiểu chủ đề.
4. Qdrant tìm Top-K vector tương tự, chỉ trong document IDs user đã chọn.
5. Evidence gate: nếu không có chunk thì từ chối, Gemini không chạy.
6. Có evidence: Gemini 3.5 Flash nhận question + vài turn gần + Top-K chunks, sinh answer. Citation lấy metadata thật và UI lưu history SQLite.

Điểm bảo vệ quan trọng

Citation không do Gemini bịa. Metadata đi theo chuỗi: document_loader - chunking - Qdrant payload - Evidence - Streamlit. Không có evidence thì Rô nói chưa tìm thấy đủ thông tin, thay vì trả lời ngoài Knowledge Base.

Câu trả lời vấn đáp và checklist demo

Thầy hỏi	Trả lời ngắn, đúng trọng tâm
Embedding chạy ở đâu?	Trong embedding_service.py. multilingual-e5-small chạy local trên backend, biến text thành vector số, không sinh câu trả lời.
Gemini dùng tại đâu?	Trong llm_service.py: client.models.generate_content(model=settings.gemini_model, ...). Đây là generation inference cloud Google.
Tại sao dùng E5-small?	Hỗ trợ tiếng Việt/đa ngôn ngữ, nhẹ cho laptop. Prefix passage: và query: đúng quy ước E5.
Qdrant khác SQLite thế nào?	Qdrant tìm vector giống nghĩa. SQLite lưu document registry, trạng thái và lịch sử chat.
Vì sao không gọi Gemini ngay?	Phải retrieval evidence trước. Nếu rỗng, evidence gate chặn để hạn chế hallucination và bảo đảm câu trả lời có nguồn.
Đổi model cần làm gì?	Đổi Gemini thường không cần re-index. Đổi embedding model phải re-index vì vector space/dimension có thể khác.

Checklist 60 giây trước demo

1. Chạy FastAPI cổng 8123. 2. Chạy Streamlit cổng 8501. 3. Kiểm tra /health. 4. Mở Kho tài liệu để thấy document READY. 5. Vào Hỏi Rõ, chọn tài liệu và hỏi. 6. Mở Góc kiểm tra để chỉ Top-K evidence, model và citation. 7. Nếu Gemini lỗi mạng/key, vẫn trình bày đúng luồng đến evidence gate, không bịa kết quả.